

TUGAS PERTEMUAN 8

Proyek Causal Discovery: PC Algorithm / GES pada Dataset Nyata

Mata Kuliah Pemodelan Kausal — Magister Informatika, Universitas Islam Indonesia

1. Deskripsi Tugas

Pada pertemuan ini, mahasiswa diminta menerapkan algoritma causal discovery — PC Algorithm (Pertemuan 5) atau GES (Pertemuan 6) — pada sebuah permasalahan dan dataset nyata yang dipilih sendiri. Tugas ini adalah proyek mini individu yang menggabungkan kemampuan merumuskan pertanyaan kausal, menilai kesesuaian data, menjalankan algoritma causal discovery, dan menginterpretasikan hasilnya secara kritis dalam konteks domain permasalahan.

Hasil pekerjaan pada tahap ini berupa draft awal laporan, yang akan dipresentasikan secara singkat pada Pertemuan 9 untuk didiskusikan di kelas. Versi revisi dari laporan ini menjadi Laporan UAS, sehingga menggantikan soal UAS tertulis.

2. Tujuan Pembelajaran

- Mampu merumuskan pertanyaan kausal dari suatu permasalahan nyata.
- Mampu menilai kesesuaian sebuah dataset untuk causal discovery.
- Mampu menjalankan PC Algorithm atau GES pada data riil (R, paket pcalg/bnlearn).
- Mampu menginterpretasikan CPDAG/graf hasil secara kritis, termasuk asumsi dan keterbatasannya.
- Mampu menyusun laporan analisis kausal secara sistematis.

3. Tahapan Tugas

3.1 Identifikasi Permasalahan dan Dataset

- Pilih topik/permasalahan yang relevan dengan minat Anda (kesehatan, ekonomi, pendidikan, lingkungan, dunia kerja, dsb).
- Rumuskan satu pertanyaan kausal utama. Contoh: “Apakah variabel X secara kausal mempengaruhi Y, atau hubungan ini dijabatani oleh variabel lain?”. Tetapi tidak terbatas pada itu.
- Cari dataset observasional yang sesuai dengan pertanyaan tersebut (lihat kriteria pada Bagian 4 dan rekomendasi pada Bagian 5).

3.2 Eksplorasi dan Persiapan Data

- Lakukan deskripsi statistik untuk setiap variabel (ringkasan, distribusi, missing values, korelasi awal).
- Tangani missing values dan outlier — jelaskan keputusan yang diambil (hapus baris, imputasi, dll.) beserta alasannya. Tidak ada satu cara yang benar; yang penting terjustifikasi.
- Tentukan dan justifikasi CI test yang digunakan. Wajib eksplisit: sebutkan nama test, alasan pemilihan, dan kesesuaiannya dengan tipe data. Jika data mixed (ada kontinu dan diskrit), jelaskan strategi yang dipilih — diskretisasi, kernel-based CI test (KCI), atau pendekatan lain.
- Jika melakukan transformasi variabel (log, normalisasi, diskretisasi), dokumentasikan keputusan tersebut dan dampaknya terhadap asumsi algoritma.

3.3 Causal Discovery dengan PC atau GES

- Jalankan salah satu algoritma (PC atau GES). Membandingkan keduanya pada dataset yang sama menjadi nilai tambah (bonus).
- Jika menggunakan PC: lakukan sensitivity analysis dengan minimal dua nilai alpha berbeda (misalnya 0.01 dan 0.05) — bandingkan hasilnya dan diskusikan perbedaan yang muncul.
- Jika menggunakan GES: laporkan fungsi skor yang digunakan (misalnya BIC) beserta alasan pemilihannya; jika memungkinkan, bandingkan dengan satu parameter/skor alternatif.
- Tampilkan CPDAG/graf hasil secara visual (plot graf). Jika graf terlalu padat (banyak edge), laporkan juga jumlah edge dan pertimbangkan apakah ini masuk akal secara domain.
- Laporkan ringkasan tahapan skeleton dan orientasi edge (untuk PC) atau skor akhir (untuk GES) secara singkat.

3.4 Interpretasi Hasil

- Identifikasi dan jelaskan setiap edge berarah dan tidak berarah pada CPDAG. Untuk edge tidak berarah: jelaskan mengapa orientasinya tidak dapat ditentukan dari data (lihat materi orientation rules di P5).
- Diskusikan kesesuaian struktur dengan domain/literatur — pilih minimal dua edge spesifik dan argumentasikan apakah arah/ada-tidaknya edge tersebut masuk akal secara kausal.
- Wajib diskusikan ketiga asumsi utama secara eksplisit: (1) Causal Markov Condition — apakah masuk akal untuk dataset ini? (2) Faithfulness — adakah risiko pelanggaran (misalnya cancellation effect)? (3) Causal Sufficiency — sebutkan minimal satu variabel laten/confounder yang mungkin tidak terobservasi dan dampaknya terhadap hasil.
- Jika hasil sensitivity analysis (Bagian 3.3) menghasilkan graf yang berbeda antar parameter: diskusikan mana yang lebih Anda percaya dan mengapa.
- (Opsional) gunakan background knowledge/expert knowledge untuk mengorientasikan edge yang ambigu — dokumentasikan knowledge yang digunakan dan sumbernya.

3.5 Estimasi Efek Kausal

- Pilih satu pasang variabel (X, Y) yang paling relevan dengan pertanyaan kausal Anda — idealnya pasangan yang menjadi inti pertanyaan penelitian.
- Tentukan apakah efek kausal $P(Y|do(X))$ dapat diidentifikasi dari CPDAG yang ditemukan. Gunakan backdoor criterion atau frontdoor criterion (materi Pertemuan 7). Jika CPDAG masih memiliki edge tidak berarah pada jalur yang relevan, diskusikan implikasinya terhadap identifikasi.
- Jika efek IDENTIFIABLE: estimasikan efek kausal menggunakan backdoor adjustment (R: paket daggity, pcalg, atau manual). Bandingkan dengan korelasi biasa — apakah ada perbedaan? Interpretasikan maknanya.
- Jika efek TIDAK IDENTIFIABLE: jelaskan mengapa — apakah karena edge ambigu di CPDAG, confounder tidak terobservasi, atau struktur graf yang menghalangi? Apa implikasinya jika kita tetap menggunakan korelasi sebagai proksi efek kausal?
- (Opsional/bonus) Coba pasangan variabel kedua, atau bandingkan estimasi efek dengan asumsi graph yang sedikit berbeda (misalnya dengan mengorientasikan salah satu edge ambigu secara manual berdasarkan domain knowledge).

3.6 Penyusunan Laporan

- Tulis laporan singkat sesuai format pada Bagian 6.

4. Kriteria Pemilihan Dataset

Agar hasil PC/GES dapat diinterpretasikan dengan baik, dataset yang dipilih sebaiknya memenuhi kriteria berikut:

Kriteria	Anjuran
Jumlah variabel	5–12 adalah rentang ideal. Dataset dengan >15 variabel diperbolehkan, namun CPDAG yang dihasilkan kemungkinan padat — jadikan ini bahan diskusi.
Jumlah observasi	Minimal ≈50 baris. Dataset kecil boleh digunakan — rendahnya statistical power CI test harus diakui dan didiskusikan sebagai keterbatasan.
Tipe data	Semua kontinu atau semua diskrit lebih sederhana untuk pemilihan CI test. Dataset mixed type (ada kontinu + diskrit) diperbolehkan — wajib justifikasi strategi CI test yang dipilih (diskretisasi, KCI, dll.).
Missing data	Boleh ada missing values — cara penanganannya (hapus baris, imputasi mean/median/modus, dll.) harus dilaporkan dan dijustifikasi.
Konteks domain	Dianjurkan ada teori/literatur pendukung, namun dataset eksploratif tanpa ground truth pun valid. Tanpa literatur, fokuskan interpretasi pada plausibilitas logis dan diskusi asumsi.
Sumber & lisensi	Dataset harus dapat disitasi (sumber jelas). Dataset simulasi atau self-collected diperbolehkan dengan dokumentasi yang memadai.

5. Rekomendasi Sumber Dataset

Jika kesulitan menemukan permasalahan/dataset sendiri, berikut beberapa opsi yang sudah terbukti cocok untuk causal discovery (PC/GES). Mahasiswa tetap didorong mencari dataset lain yang lebih sesuai dengan minat masing-masing.

5.1 Dataset Klasik (Benchmark Causal Discovery)

- Sachs et al. (2005) — Protein Signaling Network: 11 variabel ekspresi protein sel-T, 7466 observasi, dilengkapi ground-truth graf (11 node, 17 edge) sehingga hasil PC/GES dapat dibandingkan langsung dengan struktur sebenarnya. Tersedia di paket bnlearn (<https://www.bnlearn.com/book-crc/code/sachs.data.txt.gz>) maupun pcalg.
- bnlearn repository (<https://www.bnlearn.com/bnrepository/>) — kumpulan dataset Bayesian network siap pakai, antara lain ASIA (8 variabel, diagnosis penyakit paru — cocok untuk data diskrit) dan SURVEY (penggunaan transportasi publik vs kelompok sosial).
- https://zenodo.org/records/7676616?preview_file=bnlearn_data.zip

5.2 Dataset Dunia Nyata (UCI / Kaggle / Open Data)

- UCI Machine Learning Repository (archive.ics.uci.edu) — misalnya Heart Disease, Wine Quality, Student Performance: variabel numerik/kategorikal dengan konteks domain yang kuat untuk interpretasi kausal.
- Kaggle (kaggle.com/datasets) — dataset kesehatan, ekonomi, pendidikan, lingkungan dengan berbagai ukuran; pilih yang punya dokumentasi variabel jelas.
- Our World in Data / World Bank Open Data / BPS — data panel kesehatan, ekonomi, dan lingkungan antarnegara/wilayah, baik untuk pertanyaan kausal makro (misalnya hubungan pendidikan, pendapatan, dan harapan hidup).

5.3 Dataset Bawaan Paket R

- `bnlearn::asia`, `bnlearn::alarm`, `bnlearn::sachs` — langsung dapat dimuat dengan `data("nama_dataset")` setelah `library(bnlearn)`.
- `pcalg`

6. Format Laporan

Laporan ditulis maksimal 10 halaman (tidak termasuk lampiran kode), font 11–12pt, dengan struktur berikut:

1. Pendahuluan — latar belakang masalah, rumusan pertanyaan kausal, deskripsi dan sumber dataset.
2. Metode — daftar variabel & tipe data, algoritma yang digunakan (PC/GES) beserta parameter dan alasannya, perangkat lunak/paket yang dipakai.
3. Hasil — CPDAG/graf hasil causal discovery (visualisasi), ringkasan edge yang ditemukan.
4. Interpretasi dan Diskusi — makna struktur graf, kesesuaian dengan domain/literatur, asumsi dan keterbatasan analisis.
5. Kesimpulan — ringkasan temuan dan saran untuk analisis lanjutan.
6. Lampiran — kode R/skrip lengkap (dapat direproduksi). (File terpisah)

7. Format Pengumpulan

- Tugas dikerjakan secara individu.
- Draft laporan dikumpulkan dalam format PDF sebelum Pertemuan 9 dimulai.
- Sertakan kode R/script (.R atau .Rmd) sebagai lampiran/file terpisah agar dapat direproduksi.
- Siapkan slide presentasi singkat (5–10 menit) untuk Pertemuan 9 — lihat dokumen “Panduan Presentasi Pertemuan 9”.